META-PHASE M1 — Harness-Unabhängigkeit (Build-P…

✓ ABGESCHLOSSEN

Vorregistriertes Bake-off: Claude Code vs. OpenCode · trading-bot-lizard-branch · 08.–09.07.2026

MISSION & FRAGE

Kein Bot-Feature — eine Methoden-Messung:

H_Build: Erreicht ein offener Harness (OpenCode) + festes Modell die Zuverlässigkeit von Claude Code innerhalb Toleranz Δ?

Plus 2 Feuerlöscher, unabhängig vom Ausgang:

- ▸ AGENTS.md (Harness-neutraler Einstieg)
- ▸ Kalter P4/P6-Fallback (OpenRouter)

Live-Bot & Live-Pfade: zu keinem Zeitpunkt berührt

VORREGISTRIERUNG (vor der ersten Zahl)

Δ = 10 pp P = 35 % K = 210 €

E = P×K = 73,50 € M = 120 €

Migrieren ⇔ Gap ≤ Δ UND E ≥ M

E < M ⇒ Migration vorab ausgeschlossen

Zweck damit reframed: Feuerlöscher-Test des Build-Pfads — belastbare Zahl für den Zwangsfall.

Anti-Shopping: Δ/P/K/M nach Messung unantastbar

EXPERIMENT — 20 Messtrials, vollständig isoliert

Wegwerf-Fork (Keyring neutralisiert) → Referenz-Build S1–S7 (git tags base-0…base-7) → S1–S5 × 2 Repeats × 2 Harnesse (je Trial: reset auf base-(k–1)) → trials.jsonl → analyze.py (gate_pass · wall · cost)

Testfeld: Abstain-/No-Trade-Lessons-Modul (V3-Item, vorgezogen — Specs dienen doppelt als späterer echter Bauplan)

Sonnet 5 @ high in beiden (korrigiert 08.07.) · separater API-Key, keyring-only · Trials außerhalb Handelsfenster · Cap 50 €

ERGEBNIS — 20/20 Trials, kein Budget-Stopp, kein Isolations-Vorfall

Harness	gate_pass	wall_s (μ±σ)	Spend (USD)	edit_failures
claude_code	90 % (9/10)	118,3 ± 94,3	$6,90	0
opencode	90 % (9/10)	154,5 ± 101,7	$4,37	0

Gap = 0,00 pp

per Rausch-Regel: „nicht unterscheidbar"

Step	claude_code		opencode	
S1 Modelle+Taxonomie	✗	✓	✓	✗
S2 Klassifizierer	✓	✓	✓	✓
S3 Persistenz	✓	✓	✓	✓
S4 reflect (AI-Naht)	✓	✓	✓	✓
S5 Sink+Wiring (Cross-File)	✓	✓	✓	✓

Die 2 Fails: identische Root-Cause, kein Harness-Gap

Bare `pytest` im Gate setzt sys.path nicht — ob der Import auflöst, hängt an __init__.py-Markern, die die Spec dem Agenten überlässt. Bewusst als legitimes Signal gewertet, nicht als Instrument-Bug gepatcht.

Ab S2: beide Harnesse durchgehend gate-clean.

ENTSCHEIDUNG (Regel wörtlich)

Gap 0,00 pp ≤ Δ 10 pp → TRUE

E 73,50 € ≥ M 120 € → FALSE

Migrate = FALSE → KEINE MIGRATION

Feuerlöscher-Befund: im Zwangsfall ist OpenCode + gleiches Modell ein belegter Build-Pfad (0 pp), Doc-Layers-Navigation portiert nachweislich.

DELIVERABLES (unabhängig vom Ausgang)

- ✓ AGENTS.md — Repo-Root, @ref on need-to-know
- ✓ OpenAICompatLLMClient (OpenRouter) — kalt, rein additiv, null Live-Pfad-Diff, mocked Tests
- ✓ Operator-Smoke: PASS (valid abstain) durch den echten P4-Validator; 400-Fail sauber klassifiziert
- ✓ Specs S1–S7 = fertiger Bauplan für echten Abstain-Lessons-Build (V3)

VORFÄLLE & LEARNINGS (alle offengelegt, nichts still gepatcht)

- ▸ OpenCode-Trial entkam trotz korrektem cwd in das Live-Repo → --dir + OS-Write-Lock nachgerüstet, hielt über alle 20 Trials
- ▸ Manual-Spend-Prompt crashte non-interaktiv (EOFError) → beide Harnesse parsen jetzt ihre eigene autoritative Cost-JSON
- ▸ Effort-Korrektur: Sonnet 5 defaulted auf high (nicht medium) → M1-D4 datiert korrigiert · Key-Guthaben lag zeitweise unter Cap
- ▸ Spend-Rekonziliation: $9,30 berechnet vs. $9,27 Console (0,3 %) — Messinstrument bestätigt

meta_m1_harness/ · META_M1_{PREREGISTRATION,RESULTS,DECISION,CLOSEOUT_HANDOVER}.md · AGENTS.md · phase4_research/research/llm_openai_compat.py